

PLAN DU MODULE — PANDAS : Manipulation et Analyse de Données avec Python

Présentation du Module

Ce module a pour objectif d'initier les apprenants à la bibliothèque **Pandas**, l'un des outils les plus utilisés en :

- Data Analysis,
- Data Science,
- Développement Data.

Le module combinera :

- théorie,
- démonstrations,
- exercices,
- corrections,
- mini projet final.

Objectifs pédagogiques

À la fin du module, les apprenants seront capables de :

- Comprendre le rôle de Pandas
- Manipuler des DataFrames
- Lire et explorer des données
- Filtrer et nettoyer des données
- Réaliser des analyses simples
- Comprendre la relation entre Pandas et SQL
- Utiliser Pandas dans des cas concrets

Pré-requis

Les apprenants doivent avoir :

- des bases en Python,
- une compréhension des variables,
- des notions sur les listes, fonctions et conditions.

◆ BLOC 1 — Introduction à Pandas

Recherche

- Qu'est-ce que Pandas ?
- Pourquoi utiliser Pandas ?
- Histoire et origine de Pandas
- Domaines d'utilisation de Pandas
- Différence entre Excel, SQL et Pandas
- Relation entre Python, NumPy et Pandas
- Les structures principales :
 - Series
 - DataFrame
- Installation et importation de Pandas

Exercices 1 — Découverte

1. Importer Pandas
2. Créer une Series simple
3. Créer un DataFrame
4. Afficher les premières lignes
5. Afficher les colonnes
6. Vérifier le nombre de lignes et colonnes

◆ BLOC 2 — Lecture et exploration des données

Recherche

- Lire un fichier CSV avec `pd.read_csv()`
- Lire un fichier Excel avec `pd.read_excel()`
- Comprendre :
 - `head()`
 - `tail()`
 - `info()`

- describe()
- Comprendre :
 - shape
 - columns
 - dtypes
- Comprendre les valeurs manquantes

Exercices 2 — Exploration des données

1. Charger un fichier CSV
2. Afficher les premières lignes
3. Afficher les informations du dataset
4. Afficher les statistiques descriptives
5. Identifier les colonnes numériques
6. Trouver les valeurs manquantes

◆ BLOC 3 — Sélection et filtrage

Recherche

- Sélection de colonnes
- Sélection de lignes
- loc[]
- iloc[]
- Filtrage conditionnel
- Opérateurs logiques :
 - &
 - |
- Trier les données avec sort_values()

Exercices 3 — Manipulation des données

1. Afficher une colonne
2. Afficher plusieurs colonnes
3. Filtrer les étudiants ayant plus de 20 ans
4. Filtrer les notes supérieures à 15
5. Trier les données par âge
6. Trier les notes par ordre décroissant

◆ BLOC 4 — Nettoyage des données

Recherche

- Valeurs nulles
- `isnull()`
- `notnull()`
- `dropna()`
- `fillna()`
- Suppression des doublons
- `rename()`
- `astype()`
- Gestion des types de données

Exercices 4 — Data Cleaning

1. Trouver les valeurs manquantes
2. Remplacer les valeurs nulles
3. Supprimer les doublons
4. Renommer une colonne
5. Convertir une colonne en entier
6. Nettoyer un dataset simple

◆ BLOC 5 — Analyse et agrégation

Recherche

- `mean()`
- `sum()`
- `max()`
- `min()`
- `value_counts()`
- `groupby()`
- Agrégations simples
- Calculs statistiques

Exercices 5 — Analyse de données

1. Calculer la moyenne des notes
2. Trouver la note maximale
3. Compter les catégories
4. Calculer la moyenne par groupe avec `groupby()`
5. Compter le nombre d'éléments par catégorie
6. Réaliser des statistiques simples

◆ BLOC 6 — Fusion et concaténation

Recherche

- `concat()`
- `merge()`
- Jointures simples
- Relation entre SQL JOIN et Pandas Merge

Exercices 6 — Fusion de données

1. Concaténer deux DataFrames
2. Fusionner deux tables simples
3. Afficher les données communes
4. Ajouter une nouvelle colonne

◆ BLOC 7 — Pandas et SQL

Recherche

- Relation entre Pandas et SQL
- Pourquoi utiliser Pandas avec SQL ?
- Lire des données SQL avec Pandas
- Convertir une requête SQL en DataFrame
- Sauvegarder un DataFrame dans une base de données
- Différences entre SQL et Pandas
- Similarités entre SQL et Pandas
- SQL pour l'extraction vs Pandas pour la manipulation
- Cas d'utilisation en entreprise

Exercices 7 — Pandas & SQL

1. Connecter Pandas à une base de données SQLite
2. Lire une table SQL dans un DataFrame
3. Afficher les données récupérées
4. Filtrer les données avec Pandas
5. Sauvegarder un DataFrame dans une base SQL
6. Comparer une opération SQL et Pandas

MINI PROJET FINAL

Analyse des résultats d'une promotion avec Pandas

Données

Créer un dataset contenant :

- noms des apprenants,
- notes,
- âge,
- classe.

Fonctionnalités

Analyse

- Moyenne générale
- Meilleur étudiant
- Étudiant le moins performant
- Moyenne par matière

Nettoyage

- Gestion des valeurs manquantes
- Suppression des doublons

Filtrage

- Étudiants admis/non admis
- Étudiants au-dessus de la moyenne

Fusion

- Fusionner plusieurs tables d'étudiants